

Soal 1: Fitur Utama Modern Data Warehouse

Pertanyaan: Jelaskan fitur utama yang harus dimiliki modern data warehouse untuk memenuhi kebutuhan Perusahaan X (Big Data, Real-time/Batch, Data Tidak Terstruktur).

Jawaban:

Untuk mendukung Perusahaan X yang memiliki data transaksi real-time, inventori batch, dan media sosial tidak terstruktur, Modern Data Warehouse (MDW) harus memiliki fitur berikut:

Decoupled Storage & Compute (Pemisahan Penyimpanan & Komputasi)

- **Penjelasan:** Fitur ini memisahkan lapisan penyimpanan data (storage) dari kapasitas pemrosesan (compute).
- **Relevansi Kasus:** Mengingat Perusahaan X beroperasi di 50 negara dengan volume *Big Data*, fitur ini memungkinkan perusahaan menyimpan data historis dalam jumlah tak terbatas dengan biaya murah di *Cloud Storage*, sambil melakukan skalabilitas *compute power* secara independen saat beban tinggi (misal: saat Harbolnas atau pelaporan akhir bulan) tanpa harus mengupgrade infrastruktur fisik secara permanen.

Unified Batch & Streaming Architecture (Data Lakehouse)

- **Penjelasan:** Menggunakan arsitektur *Lakehouse* yang menyatukan kemampuan *Data Lake* dan *Data Warehouse*. Tidak lagi menggunakan arsitektur Lambda yang terpisah (kompleks), melainkan menggunakan satu platform terpadu.
- **Relevansi Kasus:** Mendukung kebutuhan analisis data **Real-time** (transaksi pelanggan) dan **Batch** (inventori gudang) dalam satu *engine* dan satu tempat penyimpanan. Data streaming dapat di-query segera setelah masuk (*freshness* tinggi) tanpa perlu jalur pipa data yang terpisah total.

Native Support for Unstructured Data (Schema-on-Read)


- **Penjelasan:** Kemampuan untuk menyimpan data mentah (*raw data*) dalam format aslinya (JSON, Teks, Gambar) dan menerapkan skema hanya saat data dibaca (*schema-on-read*).
- **Relevansi Kasus:** Sangat diperlukan untuk menampung **Data Media Sosial** (ulasan, komentar) dan **Log Interaksi** yang tidak terstruktur/semi-terstruktur tanpa perlu proses transformasi yang kaku di awal, sehingga analisis sentimen dapat dilakukan lebih fleksibel.

Soal 2: Rancangan Arsitektur Modern Data Warehouse

Pertanyaan: Gambarkan rancangan arsitektur, komponen utama (Ingestion, Processing, Storage, Analytics), teknologi, dan alasan pemilihannya.

Jawaban:

A. Diagram Alur Data Sederhana: (paralel si advanced analytic sama penyajiannya)



B. Detail Komponen & Teknologi:

1. Ingestion Layer (Lapisan Pengumpulan Data):

- **Teknologi:** **Apache Kafka** (untuk Streaming) & **Apache Airflow** (untuk Batch).
- **Alasan:** Kafka mampu menangani *throughput* tinggi dari data transaksi real-time dan log klik. Airflow digunakan untuk menjadwalkan pengambilan data inventori gudang secara harian.

2. Processing Layer (Lapisan Pemrosesan):

- **Teknologi:** **Apache Spark**.
- **Alasan:** Spark adalah *unified engine* yang bisa memproses data streaming (Spark Streaming) dan data batch (inventori/marketing) sekaligus. Spark juga memiliki *library* MLlib yang kuat untuk memproses data tidak terstruktur (seperti *mining* teks ulasan media sosial).

3. Storage Layer (Lapisan Penyimpanan):

- **Teknologi:** Cloud Data Warehouse (BigQuery/Snowflake) dengan karakteristik lakehouse (decoupled storage, semi-structured support)
- **Alasan:** Keduanya mendukung penyimpanan data terstruktur dan semi-terstruktur (JSON) dengan performa tinggi. Mereka serverless, sehingga otomatis menangani skala *Big Data* dari 50 negara tanpa pusing memikirkan infrastruktur.

4. Analytics Layer (Lapisan Advance Analytic):

- **Teknologi:** **KNIME**
- **Alasan:** Platform *low-code* yang kuat untuk *data mining* dan *feature engineering*. Digunakan untuk membuat *workflow* pemodelan prediktif (seperti prediksi *churn* atau pola pembelian) yang dieksekusi memanfaatkan performa komputasi *cloud* (Spark Integration).

5. Presentation Layer (BI)

- **Teknologi:** **Tableau** atau **Power BI**.
- **Alasan:** Tools ini menyediakan visualisasi interaktif yang mudah dipahami tim manajemen, mendukung koneksi langsung ke DW, dan fitur *drill-down* untuk analisis mendalam.

Soal 3: Perancangan Dashboard

Pertanyaan: Pilih satu dashboard (misal: Penjualan Real-Time), jelaskan rancangan, metrik utama, dan jenis visualisasi.

Opsi A: Pilihan Dashboard: Dashboard Penjualan Real-Time

1. Tujuan:

Memantau performa penjualan saat itu juga untuk mendeteksi lonjakan trafik atau masalah pembayaran secara instan.

2. Rancangan & Interaktivitas:

- **Filter Interaktif:** Filter berdasarkan "Negara/Wilayah", "Kategori Produk", dan "Metode Pembayaran".
- **Alerting:** Indikator warna merah berkedip jika transaksi gagal melebihi ambang batas 5%.

3. Metrik Utama & Visualisasi:

- **Total Gross Merchandise Value (GMV) Saat Ini:** Ditampilkan dengan **Scorecard/Big Number** (Angka besar di atas) untuk melihat pendapatan *real-time*.
- **Tren Penjualan per Menit/Jam:** Menggunakan **Line Chart** (Grafik Garis) untuk melihat lonjakan atau penurunan trafik dibandingkan jam yang sama kemarin.
- **Penjualan berdasarkan Wilayah:** Menggunakan **Geospatial Map** (Peta Panas) untuk melihat negara mana yang sedang aktif berbelanja.
- **Status Pembayaran (Sukses vs Gagal):** Menggunakan **Donut Chart** atau **Stacked Bar** untuk memantau kesehatan sistem pembayaran.
- **Top 5 Produk Terlaris Saat Ini:** Menggunakan **Horizontal Bar Chart** untuk mengetahui tren produk instan.

Opsi B: Dashboard Inventori Gudang (Warehouse Inventory)

1. Deskripsi & Tujuan:

Dashboard ini ditujukan untuk Manajer Rantai Pasok (Supply Chain Manager). Tujuannya adalah memantau kesehatan stok di ratusan gudang global untuk mencegah stock-out (barang habis) dan over-stock (barang menumpuk/dead stock).

2. Rancangan Interaktivitas:

- **Filter Global:** Wilayah (Region), Kategori Produk, dan Gudang Spesifik.
- **Alert System:** Menggunakan prinsip *Pre-attentive Attributes* (Warna), baris data akan otomatis berwarna merah menyala jika stok < *Safety Stock Level*.

3. Metrik Utama & Visualisasi:

Metrik (KPI)	Jenis Visualisasi	Alasan (Prinsip Visual Encoding)
Status Stok per Wilayah	Geospatial Map (Peta Titik)	Menggunakan posisi geospasial. Titik berwarna Merah (Kritis), Kuning (Waspada), Hijau (Aman). Memudahkan identifikasi masalah regional dengan cepat.
Ketersediaan vs Permintaan	Bullet Chart	Grafik batang yang memiliki garis target (<i>threshold</i>). Membandingkan stok saat ini

		(batang) dengan <i>Safety Stock</i> (garis). Lebih hemat tempat daripada <i>Gauge Chart</i> .
Inventory Turnover Ratio	Line Chart	Menunjukkan tren perputaran barang dari waktu ke waktu (Mingguan/Bulanan). Jika garis menurun, berarti barang makin susah terjual.
Top 10 Barang Slow-Moving	Horizontal Bar Chart	Mengurutkan barang yang sudah lama tidak keluar dari gudang (dead stock). Panjang batang menunjukkan nilai uang yang "terkunci" di gudang.

Opsi C: Dashboard Kampanye Pemasaran (Marketing Campaign)

1. Deskripsi & Tujuan:

Dashboard ini untuk Chief Marketing Officer (CMO) dan tim Digital Marketing. Tujuannya mengukur efektivitas biaya iklan (ROI) dari berbagai channel dan kampanye untuk memutuskan alokasi budget bulan depan.

2. Rancangan Interaktivitas:

- **Drill-down:** Dari tampilan "Global" bisa di-klik menjadi detail per "Platform" (Instagram/Twitter) atau per "Nama Kampanye".
- **Comparison Mode:** Membandingkan performa kampanye saat ini vs kampanye periode lalu (YoY atau MoM).

3. Metrik Utama & Visualisasi:

Metrik (KPI)	Jenis Visualisasi	Alasan (Prinsip Visual Encoding)
Marketing Funnel	Funnel Chart	Visualisasi standar untuk melihat konversi bertahap: <i>Impressions</i> → <i>Clicks</i> → <i>Add to Cart</i> → <i>Purchase</i> . Membantu melihat di tahap mana pelanggan "kabur" (<i>drop-off</i>).
Return on Ad Spend (ROAS)	Grouped Bar Chart	Membandingkan Biaya Iklan (Bar 1) vs Pendapatan yang Dihasilkan (Bar 2) untuk setiap <i>Channel</i> (FB, IG, Google). Memudahkan perbandingan efisiensi antar platform.
Cost Per Acquisition (CPA)	Big Number + Sparkline	Angka besar menunjukkan biaya rata-rata untuk dapat 1 pembeli saat ini, dengan grafik garis kecil (<i>sparkline</i>) di bawahnya untuk melihat tren 30 hari terakhir.

Demografi Customer	Stacked Bar Chart (100%)	Melihat komposisi umur/gender dari audiens yang berinteraksi. Menggunakan <i>Stacked Bar</i> lebih akurat daripada <i>Pie Chart</i> untuk membandingkan komposisi.
---------------------------	---------------------------------	--

Opsi D: Dashboard Sentimen Pelanggan (Customer Sentiment)

1. Deskripsi & Tujuan:

Dashboard ini untuk Tim Brand & Customer Experience. Menggunakan data tidak terstruktur (medsos) untuk memahami persepsi publik terhadap brand Perusahaan X.

2. Rancangan Interaktivitas:

- **Word Filter:** Klik kata kunci di *Word Cloud* (misal: "Pengiriman") untuk memfilter semua grafik lain agar hanya menampilkan data terkait "Pengiriman".
- **Raw Data Viewer:** Fitur untuk melihat *tweet* atau komentar asli di bagian bawah dashboard saat grafik diklik (Transparansi Data).

3. Metrik Utama & Visualisasi:

Metrik (KPI)	Jenis Visualisasi	Alasan (Prinsip Visual Encoding)
Net Sentiment Score (NSS)	Gauge Chart / Speedometer	Menunjukkan posisi brand di skala -100 (Sangat Negatif) sampai +100 (Sangat Positif). Cocok untuk melihat "kesehatan" brand secara sekilas.
Tren Sentimen Harian	Stacked Area Chart	Menumpuk volume sentimen Positif (Hijau), Netral (Abu), Negatif (Merah) sepanjang waktu. Area chart bagus untuk melihat proporsi total volume sekaligus tren.
Top Isu / Keluhan	Horizontal Bar Chart	Mengategorikan keluhan (misal: "App Error", "Late Delivery", "Wrong Item"). Menggunakan <i>Length</i> (panjang) yang akurat untuk membandingkan frekuensi masalah.
Keyword Populer	Word Cloud	(Catatan: Walau secara analitik kurang akurat, ini efektif secara visual untuk presentasi eksekutif). Menampilkan kata-kata yang paling sering muncul dalam ulasan pelanggan.

Soal 4: Pendekatan ETL untuk Data Batch & Tidak Terstruktur

Pertanyaan: Jelaskan pendekatan ETL untuk data inventori (Batch) dan media sosial (Tidak Terstruktur) serta teknologinya.

Jawaban:

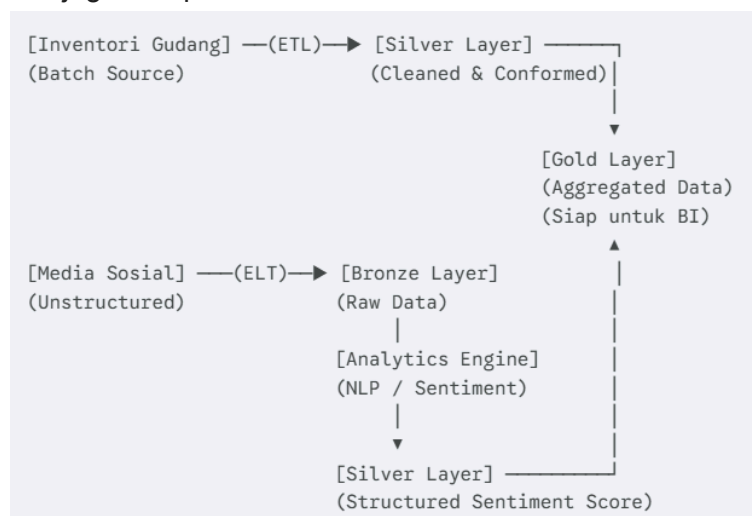
1. Penjelasan Strategi: Hybrid ETL-ELT

Untuk mengintegrasikan data inventori gudang (Batch/Terstruktur) dan data media sosial (Tidak Terstruktur), pendekatan terbaik adalah menggunakan **Hybrid ETL-ELT**. Strategi ini didasarkan pada prinsip: *"Integrate structured data early, integrate unstructured data late"*.

- **Data Terstruktur (Inventori):** Menggunakan pendekatan **ETL** (**Extract-Transform-Load**) klasik. Data dibersihkan dan distandarisasi *sebelum* masuk ke Data Warehouse untuk menjamin konsistensi dan akurasi tinggi.
- **Data Tidak Terstruktur (Media Sosial):** Menggunakan pendekatan **ELT** (**Extract-Load-Transform**) modern. Data dimuat apa adanya (*raw*) ke dalam *Data Lake*, dan transformasi (seperti analisis sentimen) dilakukan belakangan saat dibutuhkan.

2. Rancangan Arsitektur (Konsep Medallion)

Penerapan strategi ini menggunakan struktur *Medallion Architecture* (Bronze-Silver-Gold) untuk menjaga kerapian data:



3. Detail Komponen & Pendekatan

A. Integrasi Data Inventori (Pendekatan ETL)

- **Proses:** Data stok dari ratusan gudang diekstrak secara periodik (Batch Harian), divalidasi kualitasnya (*Cleansing*), dan diseragamkan formatnya (*Conforming Dimensions*) sebelum dimuat ke *Silver Layer*.
- **Alasan:** Data inventori adalah data kritis operasional yang membutuhkan skema ketat (*Schema-on-Write*) dan akurasi 100% untuk pelaporan keuangan.

B. Integrasi Data Media Sosial (Pendekatan ELT)

- **Ingestion (Extract-Load):** Data ulasan dan komentar diambil via API dan langsung disimpan ke *Bronze Layer* dalam format aslinya (JSON/Text). Ini menerapkan prinsip *Schema-on-Read* untuk menghindari hilangnya informasi kontekstual.
- **Transformation (Transform):** Menggunakan *engine* analitik (seperti Spark NLP) untuk memproses teks mentah dari *Bronze Layer*. Hasilnya berupa data terstruktur (misal: Skor Sentimen Positif/Negatif) yang disimpan di *Silver Layer*.

- **Integration:** Data skor sentimen (Silver) baru di-join dengan data penjualan/produk di *Gold Layer* untuk melihat korelasi antara "Sentimen Netizen" dengan "Penjualan Produk".

4. Rekomendasi Teknologi

- **Orchestration:** Apache Airflow
Digunakan untuk menjadwalkan workflow ETL harian (inventori) dan trigger proses NLP (medsos) secara otomatis dengan manajemen dependensi yang kuat.
- **Transformation Engine:** Apache Spark
Dipilih karena kemampuannya memproses data skala besar secara terdistribusi. Spark SQL digunakan untuk transformasi data inventori, sementara Spark MLlib digunakan untuk Natural Language Processing (NLP) pada data medsos.
- **Storage:** Google BigQuery / Snowflake
Sebagai Modern Data Warehouse yang mendukung arsitektur Lakehouse. Mampu menyimpan data relasional (hasil ETL) dan data semi-terstruktur (hasil ELT) dalam satu platform yang sama.

5. Kesimpulan

Dengan memisahkan perlakuan antara data terstruktur (ETL) dan tidak terstruktur (ELT), perusahaan mendapatkan keuntungan ganda: Kualitas Data Tinggi untuk operasional gudang, serta Fleksibilitas Analitik untuk data media sosial, tanpa membebani performa Data Warehouse utama.

Soal 5: Data Mining untuk Pola Pembelian

Pertanyaan: Bagaimana menggunakan DW untuk deteksi pola pembelian? Sebutkan teknik data mining dan dampaknya bagi strategi bisnis.

Catatan tambahan: Teknik data mining

Kebutuhan	Teknik
Segmentasi pelanggan	Clustering
Prediksi penjualan	Regression
Deteksi fraud	Classification / Anomaly
Analisis keranjang belanja	Association
Analisis sentimen medsos	Text mining

Jawaban:

1. Teknik Data Mining:

- **Market Basket Analysis (Association Rules):**
 - **Cara Kerja:** Menganalisis data transaksi historis di DW untuk menemukan pola "Jika pelanggan membeli Produk A, mereka cenderung membeli Produk B" (Contoh: Algoritma Apriori/FP-Growth).
 - **Aplikasi:** Menemukan korelasi antar produk (misal: pembeli Laptop sering membeli Mouse Wireless).
- **Clustering (K-Means / Customer Segmentation):**
 - **Cara Kerja:** Mengelompokkan pelanggan berdasarkan perilaku belanja (RFM Analysis: Recency, Frequency, Monetary).

2. Dampak pada Strategi Bisnis (Business Strategy):

- **Rekomendasi Produk (Cross-selling/Up-selling):** Berdasarkan *Market Basket Analysis*, perusahaan bisa menampilkan "Produk yang sering dibeli bersama" di halaman *checkout*, yang langsung meningkatkan rata-rata nilai pesanan (*basket size*).
- **Manajemen Inventori Cerdas:** Jika Produk A dan B sering dibeli bersama, stok keduanya bisa ditempatkan di gudang yang berdekatan untuk mempercepat pengemasan dan logistik.
- **Personalisasi Promosi:** Mengirimkan kupon diskon yang spesifik sesuai segmen/klaster pelanggan untuk mencegah *churn*.