

Modern Data Warehouse in Big Data Environment

1. Proses Analitik Bisnis Tradisional

Langkah-langkah:

1. Mulai dengan kebutuhan end-user untuk mengidentifikasi laporan dan analisis yang diinginkan
2. Definisikan skema database dan queries yang sesuai
3. Identifikasi sumber data yang dibutuhkan
4. Buat pipeline ETL (Extract-Transform-Load) untuk mengekstrak data yang dibutuhkan dan mentransformasinya ke skema target ('schema-on-write')
5. Buat laporan dan analisis data

Kelemahan: Semua data yang tidak langsung dibutuhkan akan dibuang atau diarsipkan

2. Kebutuhan Mengolah Semua Data

Big Data = All Data

- Perlu mengumpulkan semua jenis data: Structured, Unstructured, dan Streaming
- Tantangan: menggabungkan data transaksional dari database relasional dengan data yang kurang terstruktur
- Tujuan: memberikan informasi yang tepat kepada orang yang tepat, pada waktu yang tepat, dalam format yang tepat

Karakteristik Big Data (3 V's):

- Volume (ukuran data)
- Velocity (kecepatan data)
- Variety (keragaman data)

3. Data Warehousing

Definisi: Data lebih bernilai ketika diintegrasikan dari berbagai sistem. Contoh untuk melihat gambaran lengkap pelanggan:

- Aktivitas penjualan
- Invoice yang tertunggak
- Permintaan support/bantuan

Karakteristik DW:

- Dirancang user-friendly dengan terminologi bisnis
- Sering dibangun dengan model data denormalized (star schema)
- Data modeling + proses ETL memakan banyak waktu & effort

Perbedaan Transaction System (OLTP) vs Data Warehouse:

OLTP	Data Warehouse
Fokus: Transaksi operasional	Fokus: Informasi dan analitik
"Writes"	"Reads"
Scope: Satu sistem database	Scope: Integrasi data dari multiple systems
Contoh: Process customer order, Generate invoice	Contoh: Identify lowest-selling products, Analyze margin per customer

4. Data Lake

Definisi: Repositori penyimpanan yang menyimpan data dalam jumlah besar dalam format aslinya (native format) sampai data tersebut dibutuhkan.

Filosofi Big Data: "All data has value"

- Semua data memiliki nilai potensial
- Data hoarding (menyimpan semua data)
- Tidak ada skema yang didefinisikan - disimpan dalam format asli
- Skema diterapkan saat query time ('schema-on-read')
- Aplikasi dan user menginterpretasi data sesuai kebutuhan

Persyaratan Teknis Data Lake:

1. **Secure** - Harus sangat aman untuk mencegah akses tidak sah
2. **Scalable** - Harus sangat scalable karena menyimpan semua data tanpa batas waktu
3. **Reliable** - Harus highly available dan reliable (tidak ada kehilangan data permanen)
4. **Throughput** - Harus memiliki throughput tinggi untuk pemrosesan paralel masif (Hadoop, Spark)
5. **Low latency** - Harus memiliki latensi rendah untuk operasi frekuensi tinggi
6. **Details** - Harus mampu menyimpan data dengan semua detail; agregasi dapat menyebabkan hilangnya detail
7. **Native format** - Harus mengizinkan data disimpan dalam format 'native' untuk melacak lineage & data provenance
8. **All sources** - Harus mampu menerima data dari berbagai sumber (LOB/ERP, Logs, Devices, Social Networks, dll)
9. **Multiple analytic frameworks** - Harus mendukung berbagai framework analitik (Batch, Real-time, Streaming, ML, dll)

Data Lake Layers:

1. **Raw data layer** - events mentah disimpan untuk referensi historis
2. **Cleansed data layer** - events mentah ditransformasi menjadi dataset yang dapat langsung digunakan

3. **Application data layer** - logika bisnis diterapkan pada data yang sudah dibersihkan

Tujuan Data Lake:

- Mengurangi upfront effort dengan menerima data dalam format apa pun tanpa memerlukan skema awal
- Membuat akuisisi data baru menjadi mudah sehingga dapat tersedia untuk data science & analisis dengan cepat
- Menyimpan volume besar data multi-structured dalam format aslinya
- Menunda pekerjaan 'schematize' sampai nilai & kebutuhan diketahui
- Mencapai agility lebih cepat dari traditional data warehouse
- Mempercepat kemampuan decision-making
- Penyimpanan untuk tipe data tambahan yang secara historis sulit didapatkan

Use Cases Data Lake:

1. **Ingestion of New File Types** - Penyimpanan file preparatory untuk data multi-structured
2. **Data Science Experimentation/Hadoop Integration** - Big data clusters, SQL-on-Hadoop solutions, sandbox solutions
3. **Data Warehouse Staging Area** - Strategi ELT, mengurangi kebutuhan storage di platform relasional
4. **Active Archiving** - Offload aged data dari data warehouse kembali ke data lake, dengan kemampuan federated queries

Implementasi Data Lake:

- Konsep ide yang dapat diimplementasikan dengan satu atau lebih teknologi
- **HDFS** (Hadoop Distributed File Storage) adalah pilihan sangat umum tetapi bukan requirement
- **NoSQL databases** juga sangat umum
- **Object stores** (seperti Amazon S3 atau Azure Blob Storage) juga dapat digunakan

5. Pendekatan Top-Down vs Bottom-Up

Data Warehousing (Top-Down):

1. Pahami strategi korporat
2. Kumpulkan requirements (bisnis & teknis)
3. Implementasi DW (Physical Design, Dimension Modelling, ETL Design/Development, Reporting & Analytics Design/Development)

Data Lake (Bottom-Up):

1. Ingest semua data tanpa mempedulikan requirements
2. Simpan semua data dalam format native tanpa definisi skema
3. Lakukan analisis menggunakan analytic engines seperti Hadoop

Data Lake + Data Warehouse = Better Together

- Data Lake: Predictive & Prescriptive Analytics (What will happen? How can we make it happen?)
- Data Warehouse: Descriptive & Diagnostic Analytics (What happened? Why did it happen?)

6. Modern Data Warehouse

Karakteristik:

- Variety of subject areas & data sources dengan kemampuan menangani volumes besar
- Ekspansi beyond single relational DW/data mart ke Hadoop, Data Lake, atau NoSQL
- Logical design across multi-platform architecture yang menyeimbangkan scalability & performance
- Data virtualization selain data integration
- Support untuk all types & levels of users
- Flexible deployment (termasuk mobile) yang decoupled dari tool yang digunakan untuk development
- Governance model untuk mendukung trust, security, dan master data management
- Support untuk self-service solutions ke corporate environment
- Kemampuan real-time analysis pada high velocity data (Lambda architecture)
- Support untuk advanced analytics
- Agile delivery approach dengan fast delivery cycle
- Hybrid integration dengan cloud services
- APIs untuk downstream access ke data
- Beberapa DW automation untuk meningkatkan speed, consistency, & fleksibilitas adaptasi terhadap perubahan
- Data cataloging untuk memfasilitasi data search & mendokumentasikan terminologi bisnis
- Analytics sandbox atau workbench area untuk memfasilitasi agility dalam bimodal BI environment

Tantangan Modern Data Warehousing: *Agility - Complexity*:

7. Arsitektur Modern Data Warehouse

Tahapan:

1. **INGEST** - Data orchestration and monitoring (Azure Data Factory, SQL Server Integration Services)
2. **STORE** - Big data store (Azure Blob storage, Azure Data Lake Store, SQL Server)
3. **PREP & TRAIN** - Analytics engines (Azure Databricks, Azure HDInsight, Azure Data Lake Analytics, SQL Server R and Python Integration Services)

4. **MODEL & SERVE** - Data warehouse (Azure SQL Data Warehouse, Azure Analysis Services, SQL Server, SQL Server Analysis Services)

Output: BI + Reporting, Advanced Analytics, Real Time Analytics

8. Lambda Architecture

Background:

- Reference architecture untuk Big Data systems
- Designed by Nathan Marz (Twitter)
- Didefinisikan sebagai sistem yang menjalankan arbitrary functions pada arbitrary data
- "query = function(all data)"

Design Principles:

Human fault-tolerant, Immutability, Computable

Lambda Layers:

1. **Batch Layer** - Berisi immutable, constantly growing master dataset
2. **Speed Layer** - Hanya menangani data baru dan mengkompensasi high latency updates dari serving layer
3. **Serving Layer** - Memuat dan mengekspos combined view data sehingga dapat di-query

Pola Lambda yang Lebih Sederhana:

- Micro-Batch Feeds & Real-Time Queries
- Embarrassingly Parallel Speed Layer
- Transient Speed Layer
- Satu database untuk Speed & Serving (RDBMS atau NoSQL)

9. Distributed Database System

Definisi: Sistem database terdistribusi terdiri dari situs-situs yang loosely coupled yang tidak berbagi komponen fisik.

Homogeneous Distributed Database:

- Semua situs memiliki software yang identik
- Situs-situs saling mengetahui dan setuju untuk bekerja sama dalam memproses user requests
- Setiap situs menyerahkan sebagian otonominya
- Muncul kepada user sebagai single system

Heterogeneous Distributed Database:

- Situs berbeda dapat menggunakan schemas dan software berbeda
- Situs mungkin tidak saling mengetahui

Distributed Data Storage:

- **Replication** - Sistem memelihara multiple copies data di berbagai situs untuk retrieval lebih cepat dan fault tolerance
- **Fragmentation** - Relasi dipartisi menjadi beberapa fragments yang disimpan di situs berbeda

Data Transparency:

- Fragmentation transparency
- Replication transparency
- Location transparency

10. Use Cases

Cross-Channel Behavior Analytics:

- Memahami perilaku pembelian konsumen across lebih dari satu touch point
- Mengkorelasikan perilaku lintas channel (web, mobile, call center, in store, email, social)
- Tujuan: meningkatkan response rates, share of wallet, mengurangi churn, fokus pada high value customers

Recommendations:

- Mengandalkan aktivitas terkini, trends/fashion, dan propensity jangka panjang
- Mengintegrasikan insight mendalam tentang behavior dan social graph
- Membangun product recommendations/next best offer yang maksimal efektif

Kesimpulan

Modern Data Warehouse menggabungkan kekuatan:

- **Traditional Data Warehouse** untuk structured data dan reporting
- **Data Lake** untuk big data storage dan advanced analytics
- **Lambda Architecture** untuk real-time dan batch processing
- **Hybrid/Cloud solutions** untuk scalability dan flexibility

Tidak ada satu teknologi Big Data yang menyelesaikan semua masalah. Lambda architecture menyediakan cara yang powerful untuk menyelesaikan masalah yang lebih sophisticated, tetapi ada pendekatan yang lebih sederhana untuk masalah yang lebih sederhana.

Data Lakehouse - UGM

BAGIAN 1: EVOLUSI ARSITEKTUR DATA

1. Data Warehouse (DW)

Definisi: Sistem penyimpanan data terintegrasi berorientasi analisis dengan struktur tetap (schema-on-write).

Karakteristik:

- Mendukung OLAP (Online Analytical Processing)
- Menerapkan prinsip ACID:
 - **Atomicity** → operasi utuh, tidak setengah jalan
 - **Consistency** → menjaga integritas data
 - **Isolation** → transaksi tidak saling mengganggu
 - **Durability** → data tidak hilang setelah kegagalan sistem

Kelebihan: Konsistensi tinggi, dapat diaudit **Kelemahan:** Kaku terhadap format baru (video, JSON, sensor)

2. Data Lake (DL)

Definisi: Penyimpanan Big Data dengan konsep schema-on-read (skema diterapkan saat data dibaca).

Karakteristik:

- Menyimpan data terstruktur, semi-terstruktur (JSON, XML), dan tak terstruktur (video, dokumen)
- Menggunakan object storage (AWS S3, Azure Data Lake Storage)

Kelebihan: Fleksibel dan murah **Kelemahan:** Tanpa metadata dan data catalog → risiko menjadi "data swamp" (danau lumpur data)

3. Data Lakehouse (DLH)

Definisi: Menggabungkan struktur dan keandalan DW dengan fleksibilitas DL.

Karakteristik:

- Mendukung transaksi ACID di atas object storage
- Memungkinkan BI dan AI berjalan di satu sumber data
- Menggunakan ETL/ELT modern
- Platform tunggal untuk semua proses (laporan hingga ML)

Perbandingan Ringkas:

Aspek	Data Warehouse	Data Lake	Data Lakehouse
Tujuan	Laporan & BI	Penyimpanan semua jenis data	Integrasi BI & AI
Skema	Schema-on-write (fixed)	Schema-on-read (fleksibel)	Kombinasi terkendali + fleksibel
Konsistensi	ACID kuat	Lemah (raw files)	ACID melalui Delta/Iceberg
Jenis Data	Terstruktur (tabular)	Semua tipe	Semua tipe
Teknologi	Oracle DW, Teradata	Hadoop, S3, ADLS	Databricks, Snowflake, BigQuery

BAGIAN 2: KONSEP DASAR DATA LAKEHOUSE

Format Data Terbuka (Open Data Formats)

1. Apache Parquet

- Format penyimpanan kolumnar (columnar storage)
- Efisien dalam kompresi dan pencarian analitik
- Mendukung predicate pushdown dan schema evolution ringan
- Digunakan pada Raw Zone dan Curated Zone

2. Delta Lake

- Lapisan tambahan di atas Parquet
- Menambahkan kemampuan transaksi ACID, versioning, dan time travel
- Cocok untuk Lakehouse Zone (aplikasi BI dan ML)

3. Apache Iceberg

- Format tabel open-source dengan snapshot isolation
- Mendukung partition evolution (perubahan struktur partisi tanpa downtime)
- Ideal untuk organisasi besar dengan banyak alat analitik

4. Apache Hudi (Hadoop Upserts Deletes Incrementals)

- Fokus pada pemrosesan inkremental dan CDC (Change Data Capture)
- Dua mode:
 - **Copy-on-Write** → data disalin ulang setiap update (batch)
 - **Merge-on-Read** → perubahan digabungkan saat dibaca (real-time)
- Sesuai untuk skenario streaming dan data IoT

Format	Keunggulan Utama	Kekhasan Teknis	Zona Penggunaan
Parquet	Kompresi efisien, kolumnar	Predicate pushdown, schema evolution	Raw & Curated
Delta Lake	ACID + time travel	Transaction log dan rollback versi	Lakehouse
Iceberg	Snapshot isolation, multi-engine	Partition evolution, branching	Enterprise multi-tool
Hudi	Incremental dan real-time CDC	Copy-on-Write & Merge-on-Read	Streaming & IoT

BAGIAN 3: ARSITEKTUR TEKNIS DATA LAKEHOUSE UGM

Lapisan Arsitektur Lakehouse

1. Data Sources (Sumber Data)

- SIA-SIMASTER (Sistem Informasi Akademik UGM)
- LMS (Learning Management System)
- IoT kelas (sensor presensi, temperatur)
- File eksternal (CSV, Excel)

2. Ingestion Layer (Lapisan Pemasukan Data)

- **Batch:** Fivetran, dbt
- **Streaming:** Apache Kafka, Apache NiFi
- Data dikonversi ke format Parquet

3. Raw Zone (Zona Mentah)

- Semua data disimpan dalam keadaan asli di object storage (ADLS/S3)
- Prinsip schema-on-read (skema belum diterapkan)

4. Curated Zone (Zona Terolah)

- Data dibersihkan, dinormalisasi, dan divalidasi (Apache Spark/dbt)
- Format: Delta Lake atau Iceberg dengan dukungan ACID

5. Lakehouse Zone (Zona Modeling)

- Data disusun dalam bentuk dimensional model (tabel fakta dan dimensi)
- Mendukung OLAP

6. Semantic / BI Layer

- Lapisan presentasi: Power BI, Tableau, Metabase
- Data scientist mengakses dengan SQL atau Python

7. ML/AI Layer

- MLflow, Databricks ML, Vertex AI
- Model prediksi (dropout mahasiswa, rekomendasi mata kuliah)

8. Metadata & Governance Layer

- Data catalog dan lineage tracking (Apache Atlas, AWS Glue)
- RBAC (Role-Based Access Control) dan Data Masking



BAGIAN 4: DIMENSIONAL MODELING

Konsep Dasar

Dimensional Modeling: Pendekatan Ralph Kimball untuk merancang struktur data analitik yang mudah dipahami.

Komponen Utama

1. Fact Table (Tabel Fakta)

- Berisi ukuran numerik yang dapat dihitung (nilai, transaksi, kehadiran)
- Contoh: fact_student_performance

2. Dimension Table (Tabel Dimensi)

- Berisi konteks deskriptif (nama mahasiswa, kode mata kuliah, semester, dosen)
- Contoh: dim_course, dim_lecturer, dim_term, dim_student

Bentuk Model

Star Schema (Skema Bintang)

- Fact table di tengah, terhubung langsung dengan dimension table
- Sederhana dan efisien untuk query OLAP

Snowflake Schema (Skema Keping Salju)

- Dimension table dinormalisasi (memiliki sub-dimensi)
- Lebih hemat ruang tapi query lebih kompleks

Slowly Changing Dimensions (SCD)

Jenis SCD Karakteristik

Type 1 Overwrite nilai lama

Type 2 Menyimpan versi lama & baru

Type 3 Menyimpan nilai lama di kolom tambahan Menyimpan dua status terakhir mahasiswa

Contoh UGM

Dosen pindah fakultas, hanya nilai terakhir disimpan

Riwayat status mahasiswa (aktif → cuti → lulus)

Catatan: SCD Type 2 paling umum di UGM karena kebutuhan historisasi akademik.

Komponen Kunci

Komponen	Fungsi Utama
Fact Table	Menyimpan nilai agregat numerik
Dimension Table	Menyimpan atribut konteks
Grain	Tingkat detail terkecil di fact table
Surrogate Key (SK)	Kunci buatan (integer) untuk menghubungkan fact dan dimension
SCD	Mekanisme pelacakan perubahan data dimensi

BAGIAN 5: METODOLOGI CRISP-DM

6 Fase CRISP-DM

1. Business Understanding

- Memahami kebutuhan organisasi
- Menetapkan KPI akademik (IPK, presensi, retensi mahasiswa)
- Tools: Power BI, Stakeholder Workshop

2. Data Understanding

- Mengenal karakteristik dan kualitas data
- Eksplorasi data SIA-SIMASTER, LMS, IoT
- Tools: Apache Spark, Pandas Profiling

3. Data Preparation

- Menyiapkan dan membersihkan data
- Transformasi ke Delta Tables dengan ACID guarantee
- Tools: dbt, Spark SQL

4. Modeling

- Membangun model analitik
- Desain Star Schema, MLflow untuk prediksi
- Tools: Databricks, Scikit-Learn

5. Evaluation

- Menilai hasil model terhadap tujuan bisnis
- Validasi model dengan data uji dan pakar akademik
- Tools: Jupyter Notebook, Power BI

6. Deployment

- Menerapkan hasil analitik dalam sistem nyata
- Integrasi ke dashboard akademik UGM
- Tools: Azure Pipeline, Power BI Service

Sifat: Iteratif dan berkelanjutan (setelah deployment, kembali ke Business Understanding berdasarkan insight baru)

BAGIAN 6: DATA GOVERNANCE, SECURITY & QUALITY

1. Data Governance **Komponen:**

Komponen	Fungsi	Teknologi
Data Catalog	Inventaris seluruh dataset dan metadata	Apache Atlas, AWS Glue Catalog
Data Stewardship	Penanggung jawab kualitas dan definisi data	Unit Akademik & DSI UGM
Data Lineage	Jejak asal-usul dan transformasi data	Atlas Lineage, dbt Docs
Data Policy	Aturan akses dan penyimpanan	RBAC, Data Retention Policy
Metadata Management	Informasi teknis & bisnis dataset	JSON/YAML Metadata Store

2. Data Security & Privacy **Tiga Pilar Keamanan:**

Pilar	Penjelasan	Implementasi Teknis
Authentication	Verifikasi identitas pengguna	Single Sign-On (SSO UGM), Azure AD
Authorization / RBAC	Role-Based Access Control	Aturan akses berdasarkan peran (admin, dosen, peneliti)
Data Masking & Encryption	Menyembunyikan data sensitif	Masking IPK di BI, AES-256 enkripsi file Delta

3. Data Quality Management **Dimensi Data Quality:**

Dimensi	Arti	Contoh UGM
Accuracy	Ketepatan nilai terhadap sumber asli	Nilai KRS = nilai akhir SIMASTER
Completeness	Kelengkapan data	Semua mahasiswa memiliki data presensi
Consistency	Keseragaman antar sistem	Kode mata kuliah sama di SIA & LMS
Timeliness	Ketepatan waktu pembaruan	Presensi IoT masuk ≤ 5 menit
Uniqueness	Tidak ada duplikasi	Satu NIM unik per mahasiswa

BAGIAN 7: USE CASE ANALITIK & AI

Tiga Lapis Analitik

1. Descriptive Analytics (Apa yang terjadi?)

- Melihat masa lalu
- Dashboard kehadiran & IPK per fakultas
- Korelasi presensi kelas (IoT) dengan skor tugas LMS
- Tools: Power BI, SQL

2. Predictive Analytics (Apa yang akan terjadi?)

- Melihat masa depan
- Prediksi risiko drop-out mahasiswa
- Performance forecasting (IPK semester berikutnya)
- Enrollment forecasting (jumlah mahasiswa aktif tahun depan)
- Tools: MLflow, Scikit-Learn, Random Forest, XGBoost

3. Prescriptive Analytics (Apa yang sebaiknya dilakukan?)

- Memberi rekomendasi
- Early Warning Academic Advisor (notifikasi ke dosen wali)
- Rekomendasi penjadwalan kuliah otomatis
- Optimasi beban dosen
- Tools: Python AI libraries, Rule-based Engine

Contoh Implementasi: Early Warning Academic System UGM

Langkah-langkah (CRISP-DM):

1. **Business Understanding** → Tujuan: prediksi risiko akademik mahasiswa
2. **Data Understanding** → Data dari SIA-SIMASTER, LMS, IoT dikumpulkan
3. **Data Preparation** → Fitur: attendance_rate, LMS_activity, average_score
4. **Modeling** → Logistic Regression untuk Risk = High/Medium/Low
5. **Evaluation** → Akurasi 91%, AUC dan F1-score
6. **Deployment** → Dashboard Power BI dengan penanda warna merah untuk mahasiswa berisiko

Dampak: Tingkat drop-out turun dari 8% menjadi 3% dalam dua semester

ETL & ELT dalam Data Warehouse dan Data Lakehouse

1. PENGENALAN ETL & ELT

Tantangan:

- Data tersebar di berbagai sistem (OLTP Database, ERP System, APIs, File System, Streaming, CRM)
- Format, struktur, dan kualitas data berbeda-beda

Solusi:

- ETL/ELT adalah metodologi integrasi data untuk membersihkan, menyatukan, dan menyiapkan data
- Menghasilkan data yang bersih, terstruktur, dan siap untuk Business Intelligence & Analytics

2. ETL (Extract-Transform-Load) - Pendekatan Klasik

Definisi

ETL adalah proses klasik data warehousing di mana data diekstrak dari sumber, ditransformasi di luar DW (biasanya di server ETL), dan kemudian dimuat ke dalam DW setelah bersih dan terstruktur.

Karakteristik Utama:

Model Skema: Schema-on-Write: Data harus dibersihkan dan divalidasi terlebih dahulu sebelum disimpan di DW

Lokasi Transformasi: Dilakukan di server ETL khusus (di luar Data Warehouse), bukan di dalam DW

Arsitektur Ideal: Cocok untuk Traditional Data Warehouse yang berjalan on-premise dengan infrastruktur terpusat

Tools Umum: Informatica, SSIS, Talend, Pentaho, IBM DataStage

3. ARSITEKTUR ETL

4 Lapisan Utama:

1. Source Systems (Sumber Data Mentah)

- OLTP DB, ERP, APIs, Files, Streaming
- Berbagai sistem operasional yang menyimpan data transaksi dan bisnis dalam format dan struktur yang beragam

2. Staging Area (Zona Penyimpanan Sementara)

- Database/filesystem Transit
- Menampung hasil ekstraksi sebelum transformasi
- Memungkinkan isolasi beban dari sistem sumber dan memfasilitasi reprocessing data

3. ETL Engine (Lapisan Transformasi)

- Informatica, SSIS, Talend
- Melakukan cleansing, standardisasi, penggabungan data, penerapan business rules, SCD, dan pembuatan derived fields

4. Data Warehouse (Tujuan Akhir)

- Fact & Dimension Tables
- Data yang sudah bersih, terstruktur, dan siap untuk analisis
- Mendukung Business Intelligence dan reporting yang akurat

4. TRANSFORMASI DATA (Jantung dari Proses ETL)

Tahapan Kunci Transformasi:

A. Data Cleaning (Pembersihan Data)

Menangani Missing Values:

- Penghapusan baris/kolom
- Pengisian default
- Pengisian statistik (rata-rata, median, modus)
- Metode prediktif (regresi, machine learning)

Menangani Outliers:

- Deteksi: IQR, Z-score, DBSCAN
- Penghapusan nilai ekstrem
- Capping/Transformasi (logaritmik)

Menangani Duplikasi:

- Identifikasi: Exact matching atau fuzzy matching
- Tindakan: Merge atau eliminasi rekaman duplikat

Koreksi Format dan Tipe Data:

- Konversi tipe data (string ke date, string ke numeric)
- Standardisasi format tanggal (YYYY-MM-DD)
- Standardisasi format nomor telepon
- Standardisasi format email (lowercase, tanpa spasi)

B. Normalisasi dan Standardisasi

Normalisasi:

- Mengubah nilai numerik ke rentang 0 hingga 1
- Rumus: $X_{\text{norm}} = (X - X_{\text{min}}) / (X_{\text{max}} - X_{\text{min}})$
- Kegunaan: Penting untuk algoritma yang sensitif terhadap skala (KNN, Neural Networks)

Standardisasi:

- Mengubah data sehingga memiliki rata-rata nol dan deviasi standar satu (Z-score)
- Rumus: $X_{\text{std}} = (X - \mu) / \sigma$
- Kegunaan: Berguna untuk perbandingan antar variabel dengan skala berbeda

Tujuan Utama:

- Mencegah bias dalam analisis akibat perbedaan skala
- Meningkatkan performa dan konvergensi model machine learning
- Memastikan setiap fitur berkontribusi secara adil dalam pemodelan

C. Data Enrichment (Pengayaan Data)

Derivasi Kolom Baru:

- Kalkulasi metrik baru (profit = revenue - cost)
- Ekstraksi informasi (tahun dari tanggal, area code dari nomor telepon)
- Kategori berdasarkan rules (segmentasi pelanggan)

Integrasi Data Eksternal:

- Geocoding alamat (konversi alamat → latitude, longitude)
- Data demografis dari sumber eksternal
- Master data integration (informasi produk, kode referensi, daftar vendor)

D. Restructuring (Penataan Ulang)

Pivoting:

- Mengubah format 'long' menjadi 'wide'
- Contoh: Data transaksi per bulan → kolom-kolom bulan terpisah
- Berguna untuk reporting dan analisis komparatif antar periode

Unpivoting:

- Mengubah format 'wide' menjadi 'long'
- Sering digunakan untuk agregasi dan normalisasi data

Splitting:

- Memisahkan satu kolom menjadi beberapa kolom
- Contoh: "Nama Lengkap" → "Nama Depan" dan "Nama Belakang"

Combining:

- Menggabungkan beberapa kolom menjadi satu kolom
- Contoh: "Jalan" + "Kota" + "Provinsi" → "Alamat Lengkap"

5. LOADING DATA

A. Initial vs Incremental Load

Initial Load (Full Load):

- Cakupan: Loading seluruh dataset dari sumber untuk pertama kali
- Waktu Eksekusi: Saat setup awal data warehouse
- Durasi: Dapat memakan waktu lama untuk dataset besar

Incremental Load:

- Cakupan: Loading hanya data baru atau yang berubah sejak loading terakhir
- Efisiensi: Lebih efisien untuk operasi reguler harian/mingguan
- Mekanisme: Memerlukan tracking changes (timestamp, CDC - Change Data Capture)

B. Metode Loading Data

1. Insert:

- Menambahkan baris-baris baru tanpa mempengaruhi data yang sudah ada
- Use Case: Penambahan data baru dari sumber yang belum pernah dimuat

2. Update:

- Memperbarui nilai dalam baris yang sudah ada
- Use Case: Perubahan data pada record yang sudah ada (update status, harga, informasi kontak)

3. Upsert (Insert/Update):

- Kombinasi insert dan update

- Jika data sudah ada → update; jika belum ada → insert
- Use Case: Sangat umum dalam incremental load

4. Truncate and Load:

- Menghapus semua data lama, kemudian memuat seluruh dataset baru
- Use Case: Full load atau ketika perlu refresh data dari awal

C. Optimasi Loading untuk Model Data Dimensional

Dimension Loading:

- SCD (Slowly Changing Dimension): Type 1, 2, atau 3
- Referential Integrity: Mempertahankan hubungan yang valid
- Volume Data: Umumnya lebih kecil, loading lebih cepat

Fact Table Loading:

- Kecepatan Loading: Fokus pada kecepatan karena volume tinggi (jutaan hingga miliaran baris)
- Optimasi Penyimpanan: Kompresi dan partitioning
- Validasi Kunci: Memastikan kunci dimensi sudah tersedia
- Teknik: Partitioning, Bulk Insert, Indexing Strategy, Aggregation Tables

6. ELT (Extract-Load-Transform) - Pendekatan Modern

Definisi

ELT adalah pendekatan modern untuk cloud data warehouse di mana data diekstrak dari sumber, langsung dimasukkan ke dalam DW/Lakehouse, dan transformasi dilakukan di dalamnya menggunakan kekuatan MPP (Massively Parallel Processing).

Karakteristik Utama:

Model Skema:

- Load-first: Data mentah disimpan terlebih dahulu, transformasi dilakukan sesuai kebutuhan analisis

Lokasi Transformasi:

- Dilakukan di dalam Cloud DW/Lakehouse menggunakan SQL, dbt, atau warehouse-native operations

Pendorong Teknologi:

- Cloud DW modern: Snowflake, BigQuery, Redshift, Databricks dengan compute elastis dan MPP

Keuntungan Utama:

- ✓ Lebih cepat (MPP engine)
- ✓ Lebih murah (bayar sesuai query)
- ✓ Sangat fleksibel untuk data semi/unstructured

7. ARSITEKTUR ELT

3 Lapisan Utama:

1. Landing Zone / Ingestion Zone:

- Cloud Storage (S3, ADLS, GCS) untuk menyimpan data mentah
- Raw, immutable, append-only dalam format JSON, CSV, Parquet, atau Avro

2. Cloud DW / Lakehouse:

- Platform: Snowflake, BigQuery, Redshift, Databricks SQL
- Menyediakan MPP dan compute elastis untuk transformasi data berkecepatan tinggi

3. Transformasi (Di dalam DW):

- Menggunakan SQL CTE, dbt models, Window Functions, dan warehouse-native operations (MERGE, STREAMS, TASKS)

Tools & Technologies:

- Extract + Load: Fivetran, Airbyte
- Transform: dbt Cloud, SQL
- Orchestration: Airflow, Prefect
- Monitoring: Great Expectations

8. PERBANDINGAN KRITIS: ETL vs ELT

Aspek	ETL	ELT
Lokasi Transform	Server ETL (di luar DW)	Data Warehouse (di dalam DW)
Arsitektur	Traditional DW (On-Premise)	Cloud DW / Lakehouse
Model Skema	Schema-on-write (bersih dulu)	Load first, transform later

Aspek	ETL	ELT
Performansi	Terbatas pada server ETL	MPP Engine → Sangat cepat
Cost	Tinggi (Infrastruktur server)	Lebih efisien (Bayar sesuai query)
Fleksibilitas	Rendah (transformasi final)	Tinggi (transformasi fleksibel)

9. DATABRICKS vs SNOWFLAKE

Analisis Cost Model

Databricks:

- Unit Harga: Databricks Unit (DBU) - dihitung per detik
- Model Harga: Fleksibel & Kompleks
- Skenario Terbaik: Workload ETL/ML intermiten dengan variasi tinggi
- Kunci ROI: Optimasi Cluster (tuning cluster, pemilihan instance, optimasi kode)

Snowflake:

- Unit Harga: Credits - dihitung per detik, minimum 60 detik
- Model Harga: Sederhana & Prediktif
- Skenario Terbaik: Workload BI harian dengan pola konsisten
- Kunci ROI: Kontrol Warehouse (memastikan warehouse di-suspend saat tidak digunakan)

Pemilihan Platform Berdasarkan Use Case

Aspek	Databricks	Snowflake
Fokus Utama	Data Science, ML, AI, Advanced Analytics	BI, Reporting, Data Warehousing Tradisional
Tipe Data	Terstruktur, Semi-Terstruktur, Tidak Terstruktur	Terutama Data Terstruktur
Bahasa Utama	Python, Scala, R, SQL (Multi-bahasa)	SQL (Sangat Dioptimalkan)
Ekosistem	Akses Spark/MLflow, Fleksibilitas Tinggi	Terintegrasi Penuh, Zero-Maintenance

Strategi Migrasi

Databricks → Snowflake:

1. Migrasi data dari Delta Lake/S3/ADLS ke Snowflake
2. Konversi kode Spark/Python ke SQL
3. Implementasi Stored Procedures untuk logika kompleks

Snowflake → Databricks:

1. Pemanfaatan open format (Delta Lake) untuk data
2. Migrasi workload BI/SQL ke Databricks SQL (DBSQL)
3. Integrasi dengan ML/AI capabilities Databricks

Pendekatan Hybrid (Co-existence)

Databricks: Data Ingestion & Extraction, Complex ETL & Transformation, Bronze/Silver Layer Data, Machine Learning & AI, Advanced Analytics

→ **Transfer via Spark Connector atau External Tables** →

Snowflake: Final Data Mart (Gold Layer), Business Intelligence, Reporting & Dashboards, Self-Service Analytics, End-User Access & Queries

10. MEDALLION ARCHITECTURE

Struktur Data Bertahap

Bronze (Raw):

- Hasil ekstraksi data apa adanya dari berbagai sumber
- Karakteristik: Immutable, Append-only, Semua format diterima, Untuk audit & reprocessing

Silver (Cleaned):

- Data yang sudah dibersihkan dan distandardisasi
- Karakteristik: Format standar, Join dengan reference table, Data quality rules diterapkan, Sumber untuk modeling

Gold (Business-Ready):

- Data siap analisis untuk BI dan ML
- Karakteristik: Dimension & Fact Tables, Agregasi business metric, Model untuk BI/ML, Optimized untuk query

ADVANCED DATA STORYTELLING

BAGIAN 1: VISUAL ENCODING & PERCEPTION

Dasar Ilmiah Visualisasi

Konsep Inti:

- Memahami bagaimana mata dan otak memproses informasi visual adalah kunci visualisasi efektif
- Tidak semua channel visual sama efektifnya
- Prinsip Gestalt dan pre-attentive attributes membantu mengarahkan perhatian audiens
- Cognitive load management memaksimalkan pemahaman

Hierarki Akurasi Channel Visual (Cleveland & McGill)

Urutan dari paling akurat ke paling lemah:

1. **Position** - Paling akurat (scatter plot, bar chart dengan y-axis)
2. **Length** - Sangat akurat (bar chart, line chart)
3. **Angle** - Cukup akurat (slope chart, pie chart)
4. **Area** - Sedang (bubble chart, treemap)
5. **Color/Lightness** - Kurang akurat untuk data kuantitatif
6. **Shape/Orientation** - Lemah (untuk membedakan kategori saja)
7. **Volume/3D** - Paling lemah (hindari untuk data kuantitatif)

💡 Implikasi Praktis:

- Gunakan position untuk insight utama
- Warna untuk highlight atau kategori (bukan data utama)
- Hindari 3D untuk data kuantitatif
- Pilihan channel visual yang tepat meningkatkan akurasi pemahaman hingga 40%

Prinsip Gestalt dalam Data Storytelling

1. **Proximity** - Elemen yang dekat dianggap berhubungan
 - Gunakan spacing untuk mengelompokkan data terkait
2. **Similarity** - Elemen dengan warna/bentuk sama dikelompokkan bersama
 - Konsistensi visual penting
3. **Enclosure** - Elemen yang dikelilingi garis dianggap satu unit
 - Gunakan box/border untuk highlight area penting
4. **Continuity** - Mata mengikuti garis/kurva yang mulus
 - Line chart lebih mudah diikuti daripada scatter plot
5. **Connection** - Elemen yang terhubung garis dianggap berhubungan
 - Gunakan untuk menunjukkan hubungan kausal/flow
6. **Figure vs Ground** - Elemen menonjol dipersepsikan berbeda dari latar
 - Gunakan contrast untuk highlight insight utama

Pre-attentive Attributes & Cognitive Load

Pre-attentive Attributes (diproses <500ms):

1. **Color** - Paling kuat untuk menarik perhatian
2. **Size** - Elemen besar langsung terlihat
3. **Shape** - Bentuk unik menonjol
4. **Orientation** - Garis berbeda arah terlihat jelas

Cognitive Load Management:

1. **Kurangi Chartjunk** - Hapus gridline berlebihan, efek 3D, shadow
2. **Gunakan Hierarki Visual** - Insight utama menonjol dengan warna/ukuran
3. **Satu Pesan per Visual** - Jangan terlalu banyak insight dalam satu grafik
4. **Remove-to-Improve** - Setiap elemen harus punya alasan

⚖️ **Balance:** Pre-attentive attributes powerful tapi jangan berlebihan - highlight insight utama dengan satu attribute, hindari visual noise.

BAGIAN 2: CHART SELECTION & STORYTELLING

Exploratory vs Explanatory

Aspek	Exploratory	Explanatory
Tujuan	Untuk diri sendiri	Untuk stakeholder
Proses	Iteratif, berbagai angle	Linier, cerita jelas
Desain	Minimal, fokus data	Polished, dengan annotation
Interaktivitas	Sering, untuk drill-down	Minimal, untuk clarity

Aspek	Exploratory	Explanatory
Insight	Banyak kemungkinan	Satu insight utama
Output	Dashboard, notebook	Slide, laporan, presentasi

🎯 **Fokus: Explanatory Storytelling** - mengkomunikasikan insight kepada stakeholder dengan visual yang jelas, powerful, dan mudah dipahami.

Chart Selection Guide

Tujuan Cerita	Jenis Grafik	Catatan
Tren	Line chart + annotated	Annotation pada turning point/anomali
Perbandingan	Bar chart / Slope chart	Urutkan terbesar ke terkecil
Distribusi	Histogram / Density plot	Highlight anomali/cluster
Korelasi	Scatterplot + trendline	Warna untuk kategori tambahan
Komposisi	Stacked bar / Waterfall	Hindari pie chart jika >5 kategori
Ketidakpastian	Interval / Fan chart / Error bars	Jelaskan yang direpresentasikan

💡 **Prinsip:** Pilih grafik berdasarkan tujuan cerita, bukan estetika. Satu grafik = satu insight utama.

Anatomy of a Good Story Chart (5 Elemen Esensial)

- TITLE - Judul yang Menceritakan Insight**
 - ✗ "Sales 2024"
 - ✓ "Sales naik 35% di Q3 2024 didorong pasar Asia"
- SUBTITLE - Konteks dan Periode**
 - Jelaskan periode waktu, unit, batasan data
 - Contoh: "Data Januari-September 2024, 50 kota besar Indonesia"
- HIGHLIGHT - Warna Khusus untuk Insight**
 - Warna kontras untuk insight utama
 - Warna netral untuk data supporting
 - Max 2-3 warna highlight
- ANNOTATION - Penjelasan Titik Penting**
 - Anotasi pada anomali, turning point, insight utama
 - Contoh: "Penurunan 20% akibat kebijakan baru"
- CTA - Call to Action**
 - Implicit: visual sudah menyampaikan aksi
 - Explicit: tulis rekomendasi jelas
 - ✓ "Rekomendasi: Tingkatkan investasi di pasar Asia"

BAGIAN 3: COMMUNICATING MACHINE LEARNING RESULTS

1. Accuracy vs Real-World Risk

✗ "Model memiliki accuracy 95%"

✓ "Model dapat mengidentifikasi 95% dari mahasiswa berisiko DO, tetapi ada 5% yang terlewat (~10 mahasiswa per tahun). Ini berarti ada risiko kehilangan kesempatan intervensi untuk kelompok ini."

2. Precision-Recall: Kapan Lebih Relevan

- **High Precision, Low Recall:** Cocok ketika false positive mahal (diagnosis penyakit langka) - lebih baik conservative
- **High Recall, Low Precision:** Cocok ketika false negative berbahaya (deteksi fraud) - lebih baik aggressive

3. ROC Curve: Pesan yang Harus Disampaikan

✗ "ROC-AUC score adalah 0.87"

✓ "Model dapat membedakan antara mahasiswa berisiko dan tidak berisiko dengan akurasi 87%. Ini lebih baik dari random guessing (50%) tetapi masih ada ruang untuk perbaikan."

4. Lift Chart: Business Value

✓ "Model memberikan lift 3x, berarti dengan menargetkan 30% mahasiswa berisiko tinggi, kita dapat menangkap 90% dari semua mahasiswa yang akan DO. Ini menghemat resource intervensi hingga 70%."

Contoh Kasus: Evaluasi Model Prediksi Dropout Mahasiswa

Confusion Matrix (100 Sampel):

- TN=74 (Benar Negatif)
- FP=26 (Salah Positif)
- FN=26 (Salah Negatif)
- TP=74 (Benar Positif)

Metrik:

- Accuracy: 74%
- Precision: 74%
- Recall: 74%

💡 **Interpretasi Bisnis:** Model dapat mengidentifikasi **3 dari 4 mahasiswa berisiko dropout** dengan akurasi konsisten. Memberikan dasar solid untuk intervensi awal, memungkinkan institusi mengambil tindakan preventif tepat waktu.

Model Interpretability: 4 Teknik Utama

1. Feature Importance

- Bar chart top 5-10 features dengan kontribusi persentase
- Contoh: "IPK semester 1 adalah faktor paling penting (35%), diikuti SKS gagal (28%)"

2. Partial Dependence Plot (PDP)

- Line chart hubungan antara satu feature dan prediksi
- Contoh: "Saat IPK meningkat dari 2.0 ke 3.5, probabilitas DO menurun dari 80% ke 20%"

3. SHAP Value

- Waterfall chart kontribusi setiap feature untuk prediksi individual
- Contoh: "Untuk mahasiswa X: IPK rendah push risiko +40%, SKS gagal push +25%"

4. Counterfactual Explanation

- Scenario comparison "what-if"
- Contoh: "Jika IPK mahasiswa ini naik 0.5 poin, prediksi berubah dari berisiko DO menjadi tidak berisiko"

BAGIAN 4: ETHICAL STORYTELLING

Bias dalam Visualisasi

1. **Manipulasi Skala :** ✗ Y-axis tidak dari 0 (terlihat 3x lebih besar) ☒ Y-axis dari 0 (proporsional)

2. **Cherry-Picking Data :** ✗ Hanya periode yang menguntungkan ☒ Full time series yang lengkap

3. **Distorsi 3D :** ✗ 3D pie/bar chart (persepsi distorsi) ☒ Gunakan 2D

4. Efek Framing

- "Tingkat keberhasilan 95%" vs "Tingkat kegagalan 5%" - framing berbeda
- Solusi: Jelaskan konteks, gunakan multiple baselines

Equity & Inclusion

1. Kelompok Rentan Tersembunyi

- Aggregate data menyembunyikan disparitas dalam subgroup
- Solusi: Breakdown data by demographic

2. Pesan Menyinggung

- Hindari menunjukkan kelompok tertentu sebagai "masalah" tanpa konteks
- Solusi: Gunakan bahasa neutral, berikan konteks sosial-ekonomi

3. Overgeneralization

- Hindari menyimpulkan pola dari satu region ke seluruh populasi
- Solusi: Jelaskan scope data, acknowledge limitations

Transparency & Limitations

4 Aspek Transparansi:

1. Keterbatasan Data

- Jelaskan periode, scope, sample size, quality issues
- Contoh: "Data mencakup 50 kota besar, tidak termasuk area rural"

2. Noise & Variabilitas

- Tunjukkan confidence interval atau error bars
- Contoh: "Prediksi memiliki margin error $\pm 5\%$ "

3. Potensi Bias

- Jelaskan bagaimana data dikumpulkan
- Contoh: "Data dari responden online, mungkin bias terhadap tech-savvy"

4. Asumsi Model

- Jelaskan asumsi yang dibuat
- Contoh: "Model mengasumsikan hubungan linear"

4 Prinsip Utama Ethical Storytelling

1. **Transparansi** - Jelaskan keterbatasan data, noise, potensi bias, asumsi model
2. **Fairness** - Representasi adil untuk semua kelompok, hindari aggregate yang menyembunyikan disparitas
3. **Akurasi** - Interpretasi akurat, hindari cherry-picking, manipulasi skala, framing menyesatkan
4. **Accountability** - Bertanggung jawab untuk dampak cerita yang diceritakan

Evaluasi Model & Data Splitting

BAGIAN 1: PERAN EVALUASI & DATA SPLITTING

1. Capaian Pembelajaran

- **Generalization:** Kemampuan model pada data baru
- **True Risk vs Empirical Risk:** Perbedaan risiko sejati dan risiko empiris
- **Overfitting-Underfitting:** Memahami kompleksitas model yang tepat
- **Bias-Variance Trade-off:** Keseimbangan kesalahan
- **Train-Validation-Test Split:** Pembagian data yang benar
- **Data Leakage:** Mendeteksi kebocoran informasi

2. Konsep Risiko dalam Pemodelan

Empirical Risk (Risiko Empiris)

- Error pada data training set
- Yang kita lihat selama training

True Risk (Risiko Sejati)

- Error pada seluruh populasi data
- Performa pada data baru yang belum pernah dilihat

Poin Penting: Tujuan utama ML adalah meminimalkan True Risk, bukan hanya Empirical Risk.

3. Overfitting vs Underfitting

Overfitting

- Model menghafal data training
- Training error: RENDAH
- Test error: TINGGI
- Contoh: Belajar ujian dengan menghafalkan 3 soal yang sama → nilai jelek di ujian sebenarnya

Underfitting

- Model terlalu sederhana
- Training error: TINGGI
- Test error: TINGGI

Model Ideal

- Training error: RENDAH
- Test error: RENDAH

4. Skema Data Splitting: Train-Validation-Test

Set Data	Peran	Proporsi
Training Set	Belajar parameter model	60-70%
Validation Set	Tuning hyperparameter	15-20%
Test Set	Evaluasi akhir (SEKALI SAJA)	15-20%

Aturan Emas:

- Split data TERLEBIH DAHULU
- Baru lakukan preprocessing pada training set saja
- Test set HANYA untuk evaluasi final

5. Kesalahan Umum dalam Data Splitting

✗ SALAH:

1. Menggunakan test set untuk memilih model
2. Mengulang-ulang test set sampai dapat nilai bagus
3. Preprocessing sebelum split (scaling, normalisasi pada seluruh dataset)

✓ BENAR:

1. Test set hanya disentuh SEKALI di akhir
2. Preprocessing dilakukan setelah split
3. Feature selection di dalam setiap fold CV

6. Cross-Validation

Tujuan:

- Estimasi performa yang robust
- Mengurangi bias dan variance
- Memanfaatkan seluruh data

Jenis-jenis CV:

1. **K-Fold CV** ($k=5$ atau $k=10$)
 - Bagi data jadi k bagian
 - Latih k kali, setiap kali 1 fold jadi validation
 - Rata-rata hasil dari k iterasi
2. **Stratified K-Fold**
 - Untuk data imbalanced
 - Menjaga proporsi kelas di setiap fold
3. **Time Series CV**
 - Untuk data temporal
 - Training selalu masa lalu, test selalu masa depan
 - Jangan gunakan shuffle!
4. **LOOCV (Leave-One-Out)**
 - Untuk dataset sangat kecil ($n < 100$)
 - Setiap sampel jadi test sekali

BAGIAN 2: METRIK EVALUASI KLASIFIKASI & IMBALANCED DATA

1. Confusion Matrix

	Prediksi Positif	Prediksi Negatif
Aktual Positif	TP (True Positive)	FN (False Negative)
Aktual Negatif	FP (False Positive)	TN (True Negative)

2. Metrik Turunan

Metrik	Rumus	Interpretasi	Kapan Gunakan
Accuracy	$(TP + TN) / \text{Total}$	Proporsi prediksi benar	Data balanced
Precision	$TP / (TP + FP)$	Dari prediksi +, berapa yang benar?	Minimalkan false alarm
Recall	$TP / (TP + FN)$	Dari kasus +, berapa yang terdeteksi?	Minimalkan kasus terlewat
F1 Score	$2 \times (P \times R) / (P + R)$	Harmonic mean precision-recall	Balance keduanya
Specificity	$TN / (TN + FP)$	Dari kasus -, berapa yang benar?	Performa kelas negatif

3. Trade-off Precision vs Recall

Meningkatkan Recall → threshold turun → lebih banyak FP → **Precision turun**

Meningkatkan Precision → threshold naik → lebih banyak FN → **Recall turun**

Kapan prioritaskan?

- **Spam Detection:** Precision tinggi (jangan kirim email penting ke spam)
- **Disease Detection:** Recall tinggi (jangan lewatkan penyakit berbahaya)
- **Fraud Detection:** Keduanya penting

4. ROC Curve & AUC

ROC Curve: Plot TPR (Recall) vs FPR di berbagai threshold

AUC (Area Under Curve): 0-1

- AUC = 0.5: Model random
- AUC = 1.0: Model sempurna
- AUC = Probabilitas model ranking contoh positif lebih tinggi dari negatif

Kelemahan: Kurang informatif untuk data sangat imbalanced

5. Precision-Recall Curve

PR Curve: Plot Precision vs Recall

Kapan gunakan?

- Data sangat imbalanced (99:1, 95:5)
- Fokus pada kelas minoritas (positif)
- Contoh: fraud detection, anomaly detection, diagnosis penyakit

PR-AUC lebih informatif daripada ROC-AUC untuk imbalanced data

6. Metrik untuk Imbalanced Data

Metrik	Formula	Kapan Gunakan
Balanced Accuracy	$(\text{Recall}_0 + \text{Recall}_1) / 2$	Imbalance ringan (90:10)
G-Mean	$\sqrt{(\text{TPR} \times \text{TPR})}$	Imbalance sedang (95:5)
Cohen's Kappa	$(\text{Acc} - \text{ExpAcc}) / (1 - \text{ExpAcc})$	Imbalance ekstrem (99:1)

7. Sampling untuk Imbalanced Data

Oversampling: Gandakan sampel minoritas

- Pro: Tidak ada informasi hilang
- Con: Risiko overfitting

Undersampling: Kurangi sampel mayoritas

- Pro: Komputasi lebih cepat
- Con: Informasi berkurang

CRITICAL: Sampling HARUS dilakukan dalam CV, bukan sebelum split!

8. Studi Kasus: Fraud Detection (1% Fraud)

Model A (Naive): Selalu prediksi "legitimate"

- Accuracy: 99%
- Recall Fraud: 0%
- **KESIMPULAN:** Tidak berguna!

Model B (Proper): Deteksi fraud dengan cutoff optimal

- Accuracy: 92%
- Recall Fraud: 78%
- Precision Fraud: 52%
- **KESIMPULAN:** Lebih rendah accuracy, tapi mendeteksi fraud!

BAGIAN 3: EVALUASI UNTUK REGRESI & CROSS-VALIDATION

1. Metrik Regresi

Metrik	Rumus	Karakteristik	Kapan Gunakan
MSE	$\sum (y - \hat{y})^2 / n$	Sensitif outlier, satuan kuadrat	Optimisasi, hukum outlier berat
RMSE	$\sqrt{\text{MSE}}$	Sensitif outlier, satuan asli	Interpretable, hukum outlier
MAE	$\sum y - \hat{y} / n$	Robust outlier, satuan asli	Data dengan outlier
MAPE	$\sum y - \hat{y} / y / n \times 100\%$	Persentase error	Target tidak ada nilai 0
R²	$1 - (\text{SS}_{\text{res}} / \text{SS}_{\text{tot}})$	Goodness-of-fit (0-1)	Perbandingan model

2. Sensitivitas terhadap Outlier

Contoh:

- Error normal [2,-2,2,-2,2] → MSE=4, RMSE=2.0, MAE=2.0
- Dengan 1 outlier [2,-2,2,-2,50] → MSE=503, RMSE=22.4, MAE=11.6

Insight: MSE/RMSE melonjak 126x, MAE hanya 5.8x karena outlier!

3. Strategi Cross-Validation

Strategi	Deskripsi	Pro	Con	Dataset
K-Fold	Bagi jadi k fold	Standar, mudah	Variance tinggi untuk k kecil	n > 1000
Stratified K-Fold	Jaga proporsi kelas	Distribusi terjaga	Hanya klasifikasi	Imbalanced
Repeated K-Fold	K-Fold dengan seed berbeda	Kurangi variance	Biaya tinggi	n < 1000
LOOCV	Setiap sampel jadi test	Bias rendah	Sangat lambat	n < 100

4. Time-Series Evaluation

⚠ CRITICAL: Jangan gunakan shuffle split untuk time-series!

3 Pendekatan Time-Aware:

1. Time-Based Split

- Split di 1 titik waktu
- Training: masa lalu | Test: masa depan
- Sederhana tapi hanya 1 split

2. Expanding Window CV

- Training set terus bertambah
- Test selalu masa depan
- Robust, multiple folds

3. Rolling Window CV

- Fixed-size training window
- Bergerak maju dalam waktu
- Mencerminkan concept drift

5. Nested Cross-Validation

Struktur 2 Loop:

- **Inner Loop:** Hyperparameter tuning
- **Outer Loop:** Evaluasi unbiased

Kapan gunakan?

- Dataset kecil
- Banyak hyperparameter
- Butuh estimasi performa yang benar-benar valid

6. Studi Kasus: Income Forecasting dengan Leakage

Pendekatan Salah (Random Split):

- Acak 24 bulan data
- Training: bulan 3,7,12,15,18,22...
- Testing: bulan 2,8,14,19,24
- **MAPE: 2.1%** ← OVEROPTIMISTIC!
- Problem: Data masa depan masuk training!

Pendekatan Benar (Rolling Window):

- Fold 1: Train[1-12], Test[13-15]
- Fold 2: Train[1-15], Test[16-18]
- Fold 3: Train[1-18], Test[19-21]
- Fold 4: Train[1-21], Test[22-24]
- **MAPE: 7.8%** ← REALISTIC!

Insight: Perbedaan 3.7x lipat! Random split sangat menyesatkan!

7. Checklist Sebelum Deployment

✓ Evaluasi methodology benar:

- Preprocessing dalam CV
- No data leakage
- Time-aware evaluation (jika time-series)

✓ Metrik konsisten:

- Training $\approx$ validation $\approx$ test

✓ Error analysis dilakukan:

- Pahami jenis error yang dibuat model

✓ Baseline comparison:

- Model lebih baik dari baseline sederhana

✓ Business validation:

- Metrik align dengan business goals

✓ Monitoring plan:

- Rencana monitor performa, detect drift, retrain schedule