

ARSITEKTUR PLATFORM BIG DATA UNTUK MANAJEMEN METADATA

PENELITIAN BERSKALA BESAR BERBASIS PRINSIP FAIR

Tipe Data Ingestion

Dua jalur paralel (Lambda) : Batch Layer untuk akurasi historis dan Speed Layer untuk real-time, dipadukan di Serving Layer berbasis Apache Iceberg unified.

1. Batch layer : Spark + dbt → Apache Iceberg (akurasi)
2. Speed layer : Kafka → Flink → Iceberg streaming (freshness)
3. Serving layer : Apache Iceberg + Druid (unified query view)
4. Orkestrasi : Apache Airflow (scheduling batch + stream jobs)
5. Use case : Hybrid: bulk historical dump + real-time metadata feed

Karakteristik repositori riset mencakup dua ranah utama: (1) data historis masif yang dikelola dalam domain batch; serta (2) aliran metadata baru secara real-time pada domain stream. Melalui arsitektur Lambda, kedua proses tersebut dieksekusi secara independen. Implementasi Apache Iceberg pada Serving Layer memfasilitasi integrasi antara batch commits dan streaming micro-commits, guna menyajikan unified query view yang konsisten serta mutakhir bagi pengguna data.

Tahapan Data Ingestion

A. Tahap Discovery & Source Mapping

Proses identifikasi serta registrasi sumber data dilakukan melalui inventarisasi repositori personal di tingkat institusi. Melalui pemindaian skema otomatis, pendokumentasian format, serta pencatatan kredensial koneksi ke dalam Metadata Governance Repository, tahapan ini merumuskan pemetaan komprehensif atas seluruh aset data yang tersedia.

- Integrasi tata kelola metadata dilakukan melalui **Apache Atlas** untuk pemindaian skema historis secara periodik, berdampingan dengan Schema Registry guna validasi struktur data pada aliran streaming secara real-time.
- Pemanfaatan **DataHub** sebagai katalog terpadu memfasilitasi integrasi asupan metadata yang bersumber dari pekerjaan batch (Spark, dbt) maupun aliran data (Kafka topics) ke dalam satu repositori tunggal.

Input

Titik akhir repositori personal, kredensial basis data, spesifikasi antarmuka pemrograman aplikasi (API), serta berkas kamus data yang dikumpulkan dari berbagai institusi anggota.

Output

Schema Definition, Connection Metadata, Data Dictionary entry di Metadata Governance Repository

B. Tahap Data Extraction

Proses akuisisi data dan metadata diimplementasikan melalui tiga modalitas utama: pemindaian menyeluruh (full extraction), penarikan perubahan berbasis watermark (incremental), serta mekanisme **Change Data Capture (CDC)** yang merekam mutasi pada transaction log basis data secara real-time.

- Pemanfaatan **Sqoop** atau **Airbyte** dalam domain *batch layer* memfasilitasi *historical dump* menuju HDFS/S3, dengan mekanisme penjadwalan melalui Airflow DAGs guna mengeksekusi *initial load* serta penarikan data inkremental secara periodik.
- **Debezium** (*speed layer*) : Transmisi *real-time CDC events* dari basis data klinis menuju *Kafka topics*, guna menjamin latensi sub-detik pada asupan metadata terkini.
- **Apache NiFi** (*routing agent*) : Orkestrasi pembagian trafik data dilakukan melalui segregasi objek; berkas volume besar diarahkan menuju *batch path* (S3), sedangkan entitas pesan kecil dialirkan ke *stream path* (Kafka), mengonsolidasikan manajemen dua jalur dalam satu solusi tunggal.

Input

Basis data sumber (Oracle, PostgreSQL, MySQL, MongoDB), berkas terstruktur (CSV, JSON, XLSX), antarmuka REST/FHIR API, sistem EMR/EHR, serta sensor IoT dan instrumen laboratorium.

Output

Koleksi rekaman ekstraksi mentah dalam bentuk berkas statis (*batch*) maupun aliran pesan peristiwa yang berkelanjutan pada *Kafka topics* (*stream*).

C. Data Transport

Proses pemindahan data dari titik akuisisi menuju *landing zone* diimplementasikan melalui dua jalur utama: protokol transfer berkas pada *batch layer*, serta sistem perpesanan terdistribusi sebagai *commit log* yang *durable* pada *stream layer*. Guna menjamin keamanan aset informasi sensitif, penerapan enkripsi **TLS end-to-end** menjadi mandat utama sesuai dengan standar regulasi *FAIR AI.1* serta kepatuhan terhadap kebijakan perlindungan data.

- Penyimpanan berkas pada *S3/HDFS (batch layer)*: Penempatan berkas batch ke dalam *raw bucket* memicu **S3 Event Notifications** untuk menginisiasi pemrosesan lanjutan pada *Glue atau Spark*.
- **Kafka topics (speed layer)**: Aliran *real-time events* diarahkan menuju topik Kafka khusus untuk tiap penyedia data, dengan konfigurasi *retention period* selama 7 hingga 30 hari guna mendukung mekanisme pemrosesan ulang data.
- Implementasi enkripsi **TLS/SSL** bersifat wajib pada kedua jalur transmisi, mencakup *HDFS Transparent Encryption* untuk domain *batch* serta protokol *Kafka SSL* pada *speed layer* guna memitigasi risiko kebocoran data penelitian sensitif selama proses pemindahan.

Input

Koleksi rekaman ekstraksi mentah (*extracted records*) maupun aliran pesan peristiwa (*raw events*) yang bersumber dari hasil pelaksanaan tahap ekstraksi sebelumnya.

Output

Aset data dalam masa transisi: tersedia pada *Kafka topics* (jalur *stream*) maupun koleksi berkas statis dalam *object storage landing zone* (jalur *batch*).

D. Landing Zone / Staging

Implementasi repositori *raw data* dilakukan pada **zona immutable** tanpa intervensi transformasi. Area ini beroperasi sebagai buffer transisi, *audit checkpoint*, serta basis mekanisme *reprocessing* berkala. Keberadaan fase ini sangat krusial guna menjamin *reproducibility* riset sesuai prinsip **FAIR R1.2** sekaligus memenuhi standar kepatuhan audit data.

- **Penyimpanan pada S3/HDFS (batch layer)**: Pengelolaan berkas mentah bersifat *immutable* hasil ekstraksi batch beroperasi sebagai *primary source of truth* guna memfasilitasi kalkulasi ulang pada domain *batch layer* sewaktu-waktu.
- **Kafka topics (speed layer buffer)**: Aliran *real-time events* dikonsolidasikan sebagai penyangga sebelum fase pengolahan oleh Flink, dengan penerapan *offset management* guna menjamin integritas pengiriman data melalui semantik *at-least-once* maupun *exactly-once*.

- **Pemanfaatan S3 sebagai Landing Zone Terpadu:** Integrasi jalur *batch* melalui mekanisme *file drop* serta asupan *stream* via *S3 Sink* bermuara pada *S3 raw zone*, guna mewujudkan unifikasi penyimpanan dalam satu arsitektur dua jalur.

Input

Aset informasi dalam masa transisi yang berasal dari fase pemindahan data, mencakup koleksi berkas statis maupun aliran pesan pada *Kafka events*.

Output

Aset *raw data* yang tersimpan secara *immutable* pada *landing zone*; memfasilitasi mekanisme *reprocessing* melalui prosedur *replay* sewaktu-waktu guna menjaga integritas informasi tanpa risiko kehilangan data.