

1a. Definisi Data Science, Machine Learning, Artificial Intelligence, dan Business Intelligence

Artificial Intelligence (AI): Cabang ilmu komputer yang berfokus pada pembuatan sistem yang dapat meniru kecerdasan manusia, seperti penalaran, persepsi, dan pengambilan keputusan. AI adalah konsep paling luas yang mencakup semua teknik yang membuat mesin 'cerdas'.

Machine Learning (ML): Subbidang AI yang memberikan kemampuan kepada sistem untuk belajar secara otomatis dari data tanpa diprogram secara eksplisit. ML menggunakan algoritma seperti Decision Tree, SVM, Neural Network untuk menemukan pola.

Data Science: Disiplin ilmu interdisipliner yang menggabungkan statistik, pemrograman, dan domain knowledge untuk mengekstrak wawasan bermakna dari data. Data Science mencakup pengumpulan, pembersihan, eksplorasi, pemodelan, dan visualisasi data.

Business Intelligence (BI): Serangkaian teknologi, proses, dan alat yang digunakan untuk mengumpulkan, mengintegrasikan, menganalisis, dan menyajikan informasi bisnis. BI berfokus pada data historis dan pelaporan untuk mendukung pengambilan keputusan strategis.

Hubungan Keempat Bidang:

AI adalah konsep paling luas. ML adalah subset dari AI. Data Science menggunakan ML sebagai salah satu tools-nya, namun juga mencakup proses non-ML seperti statistik deskriptif dan EDA. BI adalah aplikasi bisnis yang dapat menggunakan teknik-teknik dari Data Science dan AI untuk pelaporan dan analitik.

Aspek	AI	ML	Data Science	BI
Tujuan	Meniru kecerdasan manusia	Belajar dari data	Mengekstrak insight dari data	Mendukung keputusan bisnis
Fokus	Otomasi cerdas	Prediksi & pola	Analisis komprehensif	Pelaporan & monitoring
Output	Sistem cerdas	Model prediktif	Insight & rekomendasi	Dashboard & laporan
Pendekatan	Berbasis rules & learning	Algoritma statistik	Siklus analitik lengkap	Query & agregasi data

1c. Tiga Jenis Data Utama

Jenis Data	Definisi	Karakteristik	Contoh
Terstruktur	Data yang diorganisasi dalam format tabel dengan skema tetap (baris dan kolom)	Mudah dicari & dianalisis; disimpan di RDBMS; setiap field memiliki tipe data pasti	Database relasional, spreadsheet Excel, data sensor IoT berformat CSV
Semi-Terstruktur	Data yang memiliki beberapa organisasi/tag tetapi tidak mengikuti skema tabel formal	Fleksibel namun tetap memiliki metadata; self-describing; hierarki tidak kaku	File JSON, XML, HTML, email (dengan header dan body), log aplikasi
Tidak Terstruktur	Data yang tidak memiliki format atau organisasi yang telah ditentukan	Susah dianalisis secara langsung; memerlukan NLP/CV; volume sangat besar	Teks bebas, gambar, video, audio, postingan media sosial, dokumen Word

SOAL 2


2a. Box-Plot Variabel Usia

Data Usia seluruh 10 pelanggan: [25, 40, 35, 60, 20, 50, 45, 30, 55, 15]

Data diurutkan: [15, 20, 25, 30, 35, 40, 45, 50, 55, 60]

Statistik	Nilai	Keterangan
Minimum	15	Nilai terkecil (ID 10)
Q1 (Kuartil 1)	25	Median dari separuh bawah: [15,20,25,30,35] = 25
Q2 / Median	37.5	Rata-rata nilai tengah: $(35+40)/2 = 37.5$
Q3 (Kuartil 3)	50	Median dari separuh atas: [40,45,50,55,60] = 50
Maksimum	60	Nilai terbesar (ID 4)
IQR	25	$Q3 - Q1 = 50 - 25 = 25$
Batas Bawah (Lower Fence)	-12.5	$Q1 - 1.5 \times IQR = 25 - 37.5 = -12.5$
Batas Atas (Upper Fence)	87.5	$Q3 + 1.5 \times IQR = 50 + 37.5 = 87.5$

Representasi Box-Plot:



Kesimpulan distribusi variabel Usia:

Tidak ada outlier karena semua nilai berada di antara batas bawah (-12.5) dan batas atas (87.5)

Distribusi relatif simetris: median (37.5) berada di tengah antara Q1 (25) dan Q3 (50)

Rentang usia cukup lebar (15-60 tahun), menunjukkan keragaman usia pelanggan

IQR = 25, artinya 50% data tengah berada di rentang usia 25–50 tahun

2b. Tabel Silang (Crosstab) Jenis Kelamin × Tingkat Risiko

Distribusi data berdasarkan Jenis Kelamin dan Tingkat Risiko:

Jenis Kelamin	Rendah	Tinggi	Total
Pria	2	3	5
Wanita	4	1	5
Total	6	4	10

Kesimpulan dari tabel silang:

Pria cenderung memiliki risiko lebih tinggi: 60% pria (3 dari 5) memiliki Tingkat Risiko Tinggi

Wanita cenderung memiliki risiko lebih rendah: 80% wanita (4 dari 5) memiliki Tingkat Risiko Rendah

Terdapat hubungan antara Jenis Kelamin dan Tingkat Risiko: Jenis kelamin pria berkorelasi dengan tingkat risiko yang lebih tinggi

Dari total 10 pelanggan, 60% memiliki Tingkat Risiko Rendah dan 40% Tingkat Risiko Tinggi

2c. Ordinal Encoding Variabel Status Pernikahan dan Tingkat Risiko

Ordinal encoding mengubah variabel kategorik ordinal menjadi angka dengan mempertahankan urutan logis.

Status Pernikahan (urutan: Belum Menikah → Menikah → Cerai):

Belum menikah -> 0 ; Menikah -> 1; Cerai -> 2

Tingkat Risiko (urutan: Rendah → Tinggi):

Rendah -> 0 ; Tinggi ->1

Hasil encoding untuk seluruh dataset:

ID	Status Pernikahan (asli)	Encoded	Tingkat Risiko (asli)	Encoded
1	Belum Menikah	0	Rendah	0
2	Menikah	1	Rendah	0
3	Menikah	1	Tinggi	1
4	Cerai	2	Tinggi	1
5	Belum Menikah	0	Rendah	0
6	Menikah	1	Rendah	0
7	Cerai	2	Tinggi	1
8	Belum Menikah	0	Rendah	0
9	Menikah	1	Tinggi	1
10	Cerai	2	Rendah	0

2d. Normalisasi Min-Max Variabel Usia

Data latih: ID 1 s/d 7 → Usia = [25, 40, 35, 60, 20, 50, 45]

Data uji: ID 8 s/d 10 → Usia = [30, 55, 15]

Rumus Min-Max Normalisasi:

$$x' = (x - x_{\min}) / (x_{\max} - x_{\min})$$

Langkah 1 – Hitung min dan max dari DATA LATIH (ID 1-7):

$$x_{\min}(\text{train}) = \min(25, 40, 35, 60, 20, 50, 45) = 20$$

$$x_{\max}(\text{train}) = \max(25, 40, 35, 60, 20, 50, 45) = 60$$

Langkah 2 – Normalisasi ID 2 (Usia = 40) menggunakan min/max train:

$$x'(\text{ID } 2) = (40 - 20) / (60 - 20) = 20 / 40 = 0.5$$

Langkah 3 – Normalisasi ID 10 (Usia = 15):

Normalisasi data uji tetap menggunakan min dan max dari data LATIH (bukan data uji), untuk mencegah data leakage:

$$x'(\text{ID } 10) = (15 - 20) / (60 - 20) = -5 / 40 = -0.125$$

Catatan: Nilai -0.125 wajar terjadi pada data uji karena usia ID 10 (15 tahun) berada di bawah nilai minimum data latih (20 tahun). Ini adalah perilaku normal dalam normalisasi min-max saat data uji berada di luar rentang data latih.

ID	Usia Asli	Min Train	Max Train	Usia Ternormalisasi
2 (data latih)	40	20	60	0.500
10 (data uji)	15	20	60	-0.125

SOAL 3

3a. Min dan Max Atribut_A pada 3-Fold Cross Validation

Dataset: 10.000 data | Data latih: 70% = 7.000 data | Data uji: 30% = 3.000 data

Pada 3-fold cross validation, data latih (7.000 data) dibagi menjadi 3 bagian (fold) yang kira-kira sama besar (~2.333 data per fold).

Iterasi	Data Training (fold yang dipakai)	Data Validasi	Jumlah Training	Min & Max Atribut_A
1	Fold 2 + Fold 3	Fold 1	~4.667 data	Dihitung dari Fold 2 U Fold 3
2	Fold 1 + Fold 3	Fold 2	~4.667 data	Dihitung dari Fold 1 U Fold 3
3	Fold 1 + Fold 2	Fold 3	~4.667 data	Dihitung dari Fold 1 U Fold 2

Poin Kunci: Pada setiap iterasi cross validation, nilai minimum dan maksimum Atribut_A yang digunakan dalam normalisasi min-max HARUS dihitung hanya dari data training fold tersebut (bukan dari seluruh 7.000 data latih, dan bukan dari fold validasi). Hal ini untuk mencegah data leakage dari fold validasi ke proses normalisasi.

Iterasi 1: min = min(Fold2 U Fold3), max = max(Fold2 U Fold3)

Iterasi 2: min = min(Fold1 U Fold3), max = max(Fold1 U Fold3)

Iterasi 3: min = min(Fold1 U Fold2), max = max(Fold1 U Fold2)

Ketiga iterasi berpotensi menghasilkan nilai min dan max yang BERBEDA-BEDA karena komposisi data training-nya berbeda

3b. Min dan Max Atribut_A saat Menguji pada Data Uji

Saat menguji kinerja model pada data uji (3.000 data yang 30% tersebut), nilai minimum dan maksimum yang digunakan dalam normalisasi min-max adalah nilai yang dihitung dari SELURUH data latih (semua 7.000 data).

Alasan: Setelah proses cross validation selesai dan model terbaik telah dipilih, model tersebut dilatih ulang menggunakan SELURUH data latih (7.000 data). Parameter normalisasi (min dan max) juga dihitung dari seluruh 7.000 data latih tersebut. Parameter normalisasi yang sama kemudian diterapkan pada data uji untuk mentransformasi fitur sebelum prediksi.

min_final = min(seluruh 7.000 data latih)

max_final = max(seluruh 7.000 data latih)

Data uji tidak boleh digunakan untuk menghitung parameter normalisasi, karena data uji harus dianggap sebagai data 'baru' yang belum pernah dilihat oleh model.

3c. Perbedaan Evaluasi Model dan Seleksi Model dalam Supervised Learning

Aspek	Evaluasi Model	Seleksi Model
Tujuan	Mengukur seberapa baik performa/generalisasi satu model tertentu pada data baru	Memilih model terbaik dari beberapa kandidat model
Pertanyaan yang dijawab	"Seberapa akurat model ini?"	"Model mana yang terbaik di antara kandidat?"
Metode	Train-test split, k-fold cross validation	Cross validation, validation set, AIC/BIC
Output	Nilai metrik (accuracy, F1, RMSE, dll.)	Satu model/konfigurasi yang dipilih
Waktu pelaksanaan	Setelah model selesai dilatih	Selama proses pengembangan/pelatihan
Contoh	Mengukur precision/recall model Random Forest pada test set	Membandingkan RF vs SVM vs KNN, lalu memilih yang terbaik

Keterkaitan: Seleksi model menggunakan teknik evaluasi (seperti cross validation) untuk membandingkan kandidat model. Setelah model terbaik dipilih (seleksi model), dilakukan evaluasi akhir pada test set yang terpisah untuk mendapatkan estimasi performa yang tidak bias (evaluasi model). Dengan demikian, evaluasi model adalah alat yang digunakan dalam proses seleksi model, dan juga digunakan di akhir untuk menilai model final.

3d. Confusion Matrix dan Precision, Recall, F1 untuk Kelas 2

$y_true = [0, 1, 2, 0, 1, 2, 0, 1, 2, 0, 1, 2, 0, 1, 1, 2]$

$y_pred = [1, 0, 2, 2, 2, 2, 0, 1, 2, 0, 1, 1, 0, 1, 1, 0]$

Langkah 1 – Buat confusion matrix 3×3 (baris = label aktual, kolom = label prediksi):

Aktual \ Prediksi	Pred = 0	Pred = 1	Pred = 2
Aktual = 0	3	1	1
Aktual = 1	1	4	1
Aktual = 2	1	1	3

Detail perhitungan confusion matrix:

Indeks	y_true	y_pred	Keterangan
0	0	1	Aktual=0, Prediksi=1 → baris 0, kolom 1
1	1	0	Aktual=1, Prediksi=0 → baris 1, kolom 0
2	2	2	Aktual=2, Prediksi=2 → baris 2, kolom 2 ✓
3	0	2	Aktual=0, Prediksi=2 → baris 0, kolom 2
4	1	2	Aktual=1, Prediksi=2 → baris 1, kolom 2
5	2	2	Aktual=2, Prediksi=2 → baris 2, kolom 2 ✓
6	0	0	Aktual=0, Prediksi=0 → baris 0, kolom 0 ✓
7	1	1	Aktual=1, Prediksi=1 → baris 1, kolom 1 ✓
8	2	2	Aktual=2, Prediksi=2 → baris 2, kolom 2 ✓
9	0	0	Aktual=0, Prediksi=0 → baris 0, kolom 0 ✓
10	1	1	Aktual=1, Prediksi=1 → baris 1, kolom 1 ✓
11	2	1	Aktual=2, Prediksi=1 → baris 2, kolom 1
12	0	0	Aktual=0, Prediksi=0 → baris 0, kolom 0 ✓
13	1	1	Aktual=1, Prediksi=1 → baris 1, kolom 1 ✓
14	1	1	Aktual=1, Prediksi=1 → baris 1, kolom 1 ✓
15	2	0	Aktual=2, Prediksi=0 → baris 2, kolom 0

Langkah 2 – Hitung TP, FP, FN untuk kelas 2:

Metrik	Formula	Nilai	Penjelasan
True Positive (TP)	Aktual=2 DAN Prediksi=2	3	Indeks 2, 5, 8
False Positive (FP)	Aktual≠2 DAN Prediksi=2	2	Indeks 3 (aktual=0), 4 (aktual=1)
False Negative (FN)	Aktual=2 DAN Prediksi≠2	2	Indeks 11 (pred=1), 15 (pred=0)
True Negative (TN)	Aktual≠2 DAN Prediksi≠2	9	Semua yang bukan kelas 2 diklasifikasi bukan kelas 2

Langkah 3 – Hitung Precision, Recall, dan F1:

Metrik	Rumus	Perhitungan	Hasil
Precision	$TP / (TP + FP)$	$3 / (3 + 2) = 3/5$	0.6 (60%)
Recall	$TP / (TP + FN)$	$3 / (3 + 2) = 3/5$	0.6 (60%)
F1-Score	$2 \times (Precision \times Recall) / (Precision + Recall)$	$2 \times (0.6 \times 0.6) / (0.6 + 0.6) = 0.72/1.2$	0.6 (60%)

Interpretasi:

Precision = 0.6: Dari semua data yang diprediksi sebagai kelas 2, 60% benar-benar kelas 2

Recall = 0.6: Dari semua data yang sebenarnya kelas 2, 60% berhasil terdeteksi

F1-Score = 0.6: Harmonic mean dari precision dan recall menunjukkan performa seimbang pada kelas 2

Model mengalami 2 False Positive dan 2 False Negative untuk kelas 2, menunjukkan ruang untuk perbaikan